Nama: Willian Yehezkiel Alvin

NIM: 2802419811

Bagian A:

1. Efek Regularisasi pada Batch Normalization

Batch Normalization (BN) menghitung mean dan varians secara terpisah pada setiap mini-batch selama proses pelatihan. Penggunaan statistik spesifik mini-batch ini memberikan sedikit noise acak ke dalam aktivasi setiap sampel data, karena nilainya bergantung pada sampel lain di batch yang sama. Noise ini mencegah jaringan bergantung berlebihan pada kombinasi bobot tertentu, sehingga menghasilkan efek regularisasi alami yang mirip dengan Dropout.

Namun, asumsi bahwa BN bisa menggantikan Dropout tidak berlaku pada kondisi batch size sangat kecil (misalnya di bawah 8). Pada batch size kecil, estimasi statistik mini-batch menjadi sangat bising dan tidak stabil, yang justru bisa merusak pelatihan. Selain itu, jika ada perbedaan statistik yang besar antara data latih dan data uji, akurasi model bisa turun drastis.

2. Degradasi Jaringan Dalam dan Formulasi Residual Pada CNN biasa tanpa residual connection, menambah jumlah lapisan justru membuat akurasi pelatihan turun karena optimasi fungsi identitas $f(x) = x$ sangat sulit dilakukan oleh gradient descent pada jaringan yang terlalu dalam.

Skip connection menyelesaikan masalah ini dengan mengubah persamaan menjadi $H(x) = F(x) + x$. Saat backpropagation, turunan terhadap input x menjadi $dH/dx = dF/dx + 1$. Angka +1 ini membuat aliran gradien bisa lewat langsung ke lapisan-lapisan awal tanpa terhambat, yang secara langsung mencegah timbulnya masalah vanishing gradient.

3. Feature Extraction vs Fine-Tuning

Perbandingan 4 Dimensi:

- Trainable Parameters: Feature Extraction hanya melatih classifier head (sekitar 5.130 parameter di ResNet-18). Fine-Tuning melatih sebagian atau seluruh backbone (8.4 juta sampai 11.1 juta parameter).
- Kebutuhan Data Latih: Feature Extraction cocok untuk data yang sangat sedikit (di bawah 1.000 gambar). Fine-Tuning butuh data lebih banyak agar tidak overfitting.
- Beban Komputasi: Feature Extraction jauh lebih ringan dan cepat per epoch dibanding Fine-Tuning.
- Risiko Destructive Gradients: Feature Extraction aman dari risiko ini karena backbone dikunci. Fine-Tuning berisiko merusak bobot pretrained jika learning rate terlalu besar.

4. Kaidah Penerapan Data Augmentation (Slide 20, 21, 23) Augmentasi data hanya dipakai pada train set untuk memperluas variasi data dan melatih model agar lebih tahan terhadap variasi alami.

Augmentasi harus dimatikan pada validation dan test set supaya hasil evaluasi konsisten, jujur, dan mencerminkan kondisi data nyata.

Contoh Tidak Layak: Penggunaan Random Grayscale atau Color Jitter ekstrem tidak cocok untuk klasifikasi ras hewan.

Alasan: Warna dan pola bulu (seperti pada ras Bengal atau Beagle) adalah ciri utama untuk membedakan ras hewan. Mengubah atau menghilangkan warna akan merusak informasi penting dari label tersebut.

5. Mitigasi Catastrophic Forgetting (Slide 28-29) Catastrophic forgetting terjadi saat proses fine-tuning terlalu agresif, sehingga gradien besar dari layer klasifikasi yang belum matang merusak fitur-fitur dasar yang sudah dipelajari model pretrained.

Dua Cara Mitigasi:

- Differential Learning Rate: Pakai learning rate sangat kecil di backbone (misal 0.0001) dan learning rate lebih besar di FC head (misal 0.001). Ini menjaga fitur dasar tetap aman sambil membiarkan FC head menyesuaikan diri.
- Gradual Unfreezing / Warmup: Latih FC head dulu selama beberapa epoch awal. Setelah bobot FC head stabil, baru buka kunci layer di atasnya secara bertahap.

Bagian B:

Tabel Konsolidasi Hasil Eksperimen

Berikut adalah rangkuman hasil dari kondisi B1 sampai B5 yang dieksekusi pada dataset Oxford-IIIT Pet (subset 10 kelas, total 998 gambar):

- Kondisi: B1 (Baseline from Scratch)
    - Model: ResNet
    - Trainable Params: 11.181.642
    - Total Params: 11.181.642
    - Learning Rate: 1e-3
    - Epoch Konvergen: 2
    - Durasi Total: 45.20 detik
    - Best Val Loss: 1.5097
    - Best Val Acc: 28.67%
    - Test Accuracy: 36.00%
    - Test Macro F1: 0.3145

- Kondisi: B2 (Feature Extraction)
    - Model: ResNet
    - Trainable Params: 5.130
    - Total Params: 11.181.642
    - Learning Rate: 1e-3
    - Epoch Konvergen: 23
    - Durasi Total: 181.22 detik
    - Best Val Loss: 0.2491
    - Best Val Acc: 91.33%
    - Test Accuracy: 88.67%
    - Test Macro F1: 0.8883
- Kondisi: B3 (Progressive Fine-Tuning)
    - Model: ResNet
    - Trainable Params: 8.398.858
    - Total Params: 11.181.642
    - Learning Rate: layer4: 1e-4, fc: 1e-3
    - Epoch Konvergen: 6
    - Durasi Total: 72.00 detik
    - Best Val Loss: 0.2346
    - Best Val Acc: 92.67%
    - Test Accuracy: 92.00%
    - Test Macro F1: 0.9204
- Kondisi: B4_NoAug (Uji Kontrol Augmentasi - Tanpa Augmentasi)
    - Model: ResNet
    - Trainable Params: 5.130
    - Total Params: 11.181.642
    - Learning Rate: 1e-3
    - Epoch Konvergen: 25
    - Durasi Total: 114.99 detik
    - Best Val Loss: 0.2441
    - Best Val Acc: 92.00%

    - Test Accuracy: 90.00%
    - Test Macro F1: 0.9009
- Kondisi: B5_EfficientNetB0 (Arsitektur Pembanding)
    - Model: EfficientNet
    - Trainable Params: 12.810
    - Total Params: 4.020.358
    - Learning Rate: 1e-3
    - Epoch Konvergen: 24
    - Durasi Total: 180.19 detik
    - Best Val Loss: 0.3048
    - Best Val Acc: 90.00%
    - Test Accuracy: 86.67%
    - Test Macro F1: 0.8658

Bagian C1:

- B1 (From Scratch): Mengalami overfitting ekstrem sejak awal. Val loss terendah dicapai hanya pada epoch ke-2 (1.5097) sebelum akhirnya terhenti oleh early stopping, menghasilkan test accuracy terendah sebesar 36.00%.
- B2 (Feature Extraction): Menunjukkan konvergensi yang sangat stabil sepanjang 23 epoch. Val loss turun secara konsisten hingga 0.2491, menghasilkan test accuracy 88.67%.
- B3 (Fine-Tuning): Menjadi kondisi terbaik. Hanya butuh 6 epoch untuk konvergen dan mencapai val loss terendah (0.2346), dengan test accuracy paling tinggi yaitu 92.00% dan Macro F1 0.9204.

Bagian C2:

1. Disparitas Performa Baseline (B1) vs. Transfer Learning (B2 & B3)

Pelatihan model dari nol (B1) menghasilkan akurasi pengujian yang sangat rendah, yaitu hanya 36.00% dengan Macro F1 sebesar 0.3145. Penyebab utamanya adalah jumlah data latih yang sangat terbatas (hanya 698 gambar atau sekitar 70 gambar per kelas). Dengan 11,18 juta parameter bebas yang harus dioptimasi dari inisialisasi acak, model B1 langsung mengalami overfitting parah. Validation loss terendah dicapai hanya pada epoch ke-2 (1.5097), dan pelatihan terhenti pada epoch ke-6 akibat early stopping.

Sebaliknya, paradigma transfer learning pada B2 dan B3 memberikan lonjakan performa yang dramatis, masing-masing mencapai akurasi uji 88.67% dan 92.00%. Hal ini terjadi karena model B2 dan B3 memanfaatkan bobot pretrained dari ImageNet yang sudah mempelajari representasi visual generik seperti deteksi tepi, tekstur, dan pola bentuk alami. Transfer learning secara efektif

memangkas kebutuhan jumlah data latih, sehingga model dapat menggeneralisasi fitur ras hewan dengan sangat baik meskipun dalam skala data kecil.

2. Trade-off Feature Extraction (B2) vs. Progressive Fine-Tuning (B3)

- B2 (Feature Extraction): Hanya melatih 5.130 parameter pada layer classifier head (fc) dengan membekukan seluruh backbone. Pendekatan ini membutuhkan waktu konvergensi yang lebih panjang (23 epoch, total durasi 181.22 detik) karena ruang pencarian parameter yang sangat terbatas. Namun, B2 sangat stabil dan menghasilkan test accuracy sebesar 88.67% tanpa risiko merusak bobot representasi awal.
- B3 (Progressive Fine-Tuning): Melatih 8.398.858 parameter dengan membuka pembekuan pada layer4 dan menerapkan differential learning rate (1e-4 untuk layer4, 1e-3 untuk fc). Hasilnya, B3 menjadi model berkinerja terbaik dengan akurasi pengujian tertinggi (92.00%) dan Macro F1 tertinggi (0.9204). Selain itu, B3 konvergen jauh lebih cepat (hanya 6 epoch, total durasi 72.00 detik) karena lapisan atas backbone disesuaikan secara langsung untuk mengekstrak fitur spesifik morfologi kucing dan anjing.

3. Peran Data Augmentation (B4_NoAug vs B2)

Pada eksperimen kontrol augmentasi, B4_NoAug (tanpa augmentasi data) menghasilkan test accuracy sebesar 90.00% dan Macro F1 0.9009, yang secara mengejutkan sedikit lebih tinggi pada data uji dibandingkan B2 dengan augmentasi (88.67%).

Namun, jika dilihat dari proses pelatihannya, B4_NoAug membutuhkan 25 epoch penuh (mencapai batas maksimum) untuk konvergen. Tanpa augmentasi, model cenderung lebih cepat menghafal pola visual yang statis pada data latih. Penerapan augmentasi aktif pada B2 (crop, flip, rotasi, dan color jitter) memberikan efek regularisasi stokastik yang mencegah model bergantung pada satu sudut pandang atau bias latar belakang tertentu, meskipun membutuhkan evaluasi yang lebih ketat pada data validasi.

4. Efisiensi Arsitektur Pembanding (B5_EfficientNetB0)

B5_EfficientNetB0 melatih 12.810 parameter pada classifier head dari total 4,02 juta parameter arsitektur. Model ini mencatatkan test accuracy 86.67% dan Macro F1 0.8658, dengan waktu konvergensi 24 epoch (180.19 detik).

Meskipun akurasi pengujian EfficientNet-B0 sedikit di bawah ResNet-18 (88.67% pada B2 dan 92.00% pada B3), EfficientNet-B0 memiliki total parameter yang jauh lebih kecil (4,02 juta dibanding 11,18 juta pada ResNet-18). Ini menunjukkan efisiensi parameter yang sangat baik, menjadikannya pilihan arsitektur yang ideal untuk skenario penyebaran pada perangkat dengan keterbatasan memori dan daya komputasi (edge devices).

Bagian C3:

Berdasarkan hasil pengujian model terbaik B3 (ResNet-18 Fine-Tuning), ditemukan 8 sampel citra dari test set yang salah diprediksi. Berikut adalah analisis teknis terhadap sampel-sampel misklasifikasi utama:

1. American Pit Bull Terrier vs. American Bulldog (Prediksi Berkeyakinan Tinggi)

- Fenomena: Beberapa sampel American Pit Bull Terrier diprediksi sebagai American Bulldog dengan confidence score yang sangat tinggi, bahkan mencapai 99.7%.
- Hipotesis Penyebab: Kemiripan bentuk fisik antar ras (inter-class similarity) yang sangat kuat pada area rahang, struktur kepala yang kekar, serta corak warna bulu kombinasi putih dan cokelat. Selain itu, adanya framing citra yang terlalu dekat (closeup) atau potongan foto yang terpotong tangan manusia menutupi proporsi tubuh utamanya, sehingga model terkecoh pada fitur wajah semata.

2. Beagle vs. Basset Hound (Kemiripan Ras Anjing Pemburu)

- Fenomena: Sampel Beagle diprediksi sebagai Basset Hound dengan keyakinan sebesar 85.4% dan 65.8%.
- Hipotesis Penyebab: Kedua ras ini memiliki karakteristik corak warna bulu tri-color (hitam, putih, dan cokelat) serta telinga panjang yang identik. Pada sampel terprediksi salah, sudut pengambilan gambar yang miring serta keberadaan aksesoris seperti harness/tali kekang menutupi pembeda utama kedua ras, yaitu panjang kaki dan proporsi tinggi badan.

3. Abyssinian vs. American Pit Bull Terrier (Distraksi Latar Belakang dan Pose Ekstrem)

- Fenomena: Kucing ras Abyssinian diprediksi sebagai anjing American Pit Bull Terrier dengan confidence score 92.7%.
- Hipotesis Penyebab: Kucing pada citra sedang dalam pose bermain dengan mulut terbuka menghadap mainan bulu yang dipegang tangan manusia. Warna bulu cokelat kemerahan dari Abyssinian yang dipadukan dengan latar belakang putih polos dan keberadaan objek tangan manusia membuat model salah mengenali tekstur dan bentuk tubuh kucing, sehingga mengasosiasikannya dengan ciri warna bulu dan bias latar belakang sampel anjing.

Bagian C4:

1. Rekomendasi Rekayasa untuk Industri

- Strategi Utama: Pada skenario industri dengan keterbatasan data berlabel (<1.000 citra), pendekatan terbaik adalah memulai pengembangan dengan Progressive Fine-Tuning (B3). Strategi ini terbukti memberikan akurasi tertinggi (92.00%) dan konvergensi tercepat (hanya 6 epoch) dengan memanfaatkan differential learning rate (1e-4 pada backbone, 1e-3 pada FC head).
- Alternatif Cepat & Stabil: Jika anggaran komputasi sangat terbatas atau sistem membutuhkan deployment berkala tanpa risiko merusak bobot awal, Feature Extraction (B2) dapat dijadikan pilihan baseline yang sangat aman (akurasi 88.67%).
- Pemilihan Arsitektur Edge Device: Untuk penyebaran pada perangkat tepi (edge/mobile devices), EfficientNet-B0 (B5) menjadi pilihan paling efisien. Dengan hanya 4,02 juta total parameter (hampir sepertiga dari ResNet-18), model ini mampu mempertahankan akurasi sebesar 86.67%.

2. Batasan Eksperimen (Limitations)

- Pengujian berbasis single seed (seed=42), sehingga variansi performa akibat inisialisasi acak belum terukur secara statistik.
- Penggunaan subset terbatas pada 10 kelas dari total 37 kelas Oxford-IIIT Pet.
- Evaluasi fine-tuning baru mencakup pelepasan pembekuan pada layer4, belum mengeksplorasi strategi gradual unfreezing secara bertahap dari layer awal.

Bagian AI disclosure:

1. Nama Alat AI: Google Gemini.

2 . Ruang Lingkup Bantuan:

- Membantu pembentukan struktur skrip PyTorch dan perbaikan error sintaks.
- Membantu penyusunan kerangka analisis dan pengecekan konsistensi format laporan.

3. Metode Verifikasi Mandiri:

- Seluruh kode dieksekusi secara mandiri pada runtime GPU Google Colab.
- Seluruh metrik dan angka performa diambil secara langsung dari log mentah data eksekusi (metrics_log.csv).
- Seluruh penjelasan konsep disesuaikan secara langsung dengan bahan tayang Sesi 05.

Github: https://github.com/Willer312/Tugas05_2802419811_WillianYehezkielAlvin_DeepLearning.git